

시계열 데이터 시각화 방법에 따른 CNN 분류 성능 민감도 분석

Sensitivity Analysis on CNN Classification Performance with Various Time Series Data Visualization Approaches

정호진¹ · 윤한얼²

Ho-Jin Jung and Han Ul Yoon

¹연세대학교 컴퓨터정보통신공학부

E-mail: hojinj@yonsei.ac.kr

²연세대학교 소프트웨어학부

E-mail: huyoon@yonsei.ac.kr

요 약

시계열 데이터의 예측/분류 문제는, 여러 가지화 기법을 통해 시계열 데이터를 이미지화 하여, CNN을 통해 푸는 것이 효율적이다. 이때, 가지화 된 이미지가 담고 있는 정보량이 예측/분류 문제의 성능에 영향을 미치게 된다. 따라서, 본 논문은 시계열 데이터를 이미지로 가지화하여 분류 정확도와 이미지의 엔트로피(Entropy), 희소성(Sparsity)을 고려한 민감도 분석(Sensitivity Analysis)을 하였다. 여러 가지 기법으로 시계열 데이터를 가지화 하고, 가지화된 이미지들의 엔트로피와 희소성을 구한 후, 분류 문제의 정확도와와의 관계를 살펴보았다. 결과를 통해, 엔트로피와 희소성 모두 분류 성능과 단조 증가의 추이를 갖는 것을 알 수 있었다.

키워드 : CNN 분류 성능 민감도 분석, 시계열 데이터 가지화

1. 서 론

시계열 데이터의 예측/분류 문제를 해결하기 위해서는, 시간에 대한 입력과 출력의 관계를 함수로 근사화할 수 있어야 한다. 그러나, 입력 데이터의 경향성과 주기성이 명확하지 않거나, 입력 데이터가 이질적인 신호들의 조합으로 이루어지는 경우, 입-출력의 관계를 함수로 표현하기 힘들다. 따라서 이러한 시계열 데이터의 예측/분류 문제를 해결하기 위해서는, 시계열 데이터의 가지화 기법들을 적용한 이미지를 CNN의 입력으로 사용하여, 입-출력 데이터 사이의 관계를 신경망으로 근사화하는 것이 효율적이다.

Yuchao Li et al.에 따르면, 이미지 엔트로피와 희소성을 기반으로 kernel sparsity entropy indicator를 유도해 CNN 모델에 파라미터로 사용하여 모델 연산량을 줄일 수 있음을 검증했다[2]. Yawei Li et al.은 CNN의 레이어에서 생성되는 피쳐맵들의 Sparsity를 drop-out 또는 weight pruning을 결정할 수 있는 방법론을 제안하였다[3]. 이는 이미지의 엔트로피와 희소성은 CNN의 분류 성능에 밀접한 관련이 있음을 말해준다.

본 논문에서는 시계열 데이터를 다양한 이미지로 가지화하고, 그에 대한 엔트로피와 희소성을 구한 후, 분류 정확도와와의 관계를 분석한다. 자세히 말하면, 사람의 이미지 인식관점에 따라 데이터를 가지화하는 L_{easy} , L_{fair} 그리고 컴퓨터 관점에서 한 이미지에 많은 정보량을 담고자 시도한 L_{chal} , 극좌표로 시계열 데이터를 표현하는 gramian angular difference field(이하 GADF), 이전 시간과 현재시간의 상태 관계를 매트릭스로 표현하는 Markov Transition Field(이하 MTF)로 시계열 데이

터를 가지화한다. 이후 가지화한 시계열 데이터를 CNN의 입력으로 넣어, 총 다섯 가지 종류의 이미지에 대한 분류 결과를 얻는다. 마지막으로 분류 정확도를 이미지화 기법들에 대한 엔트로피와 희소성 관점에서 분석한다.

2. 제안하는 방법론

2.1 실험을 통한 근전도 및 관절각 데이터 획득

숙련된 트레이너에 의해 덤벨-컬, 트라이셉스-킥백, 해머-컬, 리버스-컬 운동을 수행하도록 하였다. 수행 중에는 총 두 가지 종류의 시계열 데이터를 획득하였다. RGB-d 카메라로 팔꿈치 관절 각(이하 Angle)을, 8채널 암밴드형 근전도 센서로 채널 별 근전도(이하 sEMG) 값을 얻었다. 이때 암밴드형 근전도 센서는 1~4채널은 이두 영역이, 5~8채널은 삼두영역이 위치하게 하였다. 20ms 샘플링 시간으로 1600ms가 1회 동작이 되도록 하였다. 숙련된 트레이너의 근피로도를 고려하여 데이터를 측정하였으며, 각 운동별 60회의 데이터를 획득하였다.

2.2 이미지 가지화 기법 소개

그림 1은 획득한 데이터를 가지화하여 이미지로 나타낸 결과를 보여준다. 이미지 가지화는 아래 명시된 다섯 가지 방법을 사용하였으며, 특히 사람의 이미지 인식 관점에 따라 설계한 L_{easy} , L_{fair} , L_{chal} 의 자세한 수학적 정의는 [1]에서 확인할 수 있으며, 위 세 가지 방법은 Angle과 채널별 sEMG를, 즉 9가지 특징을 한 이미지에 통합하여 표현하는 방법이다. 그에 반해 GADF와 MTF는 각 특징 별 이미지가 각각 등장하여 하나의 동작은 9개의 이미지로 표현된다.

L_{easy} : 이두/삼두 활성화 데이터를 Angle 데이터로 구분 짓는다. 이는 사람의 관점으로 볼 때, Angle 데이터는 이두/삼두 영역을 구분 지어 각 영역의 흐름을 기하학적인 모양 관점으로 쉽게 파악할 수 있게 도와준다.

L_{fair} : 이두/삼두 활성화 데이터와 Angle 데이터를 순차




그림 1. 덤벨컬 운동 데이터 가시화 이미지: (좌측 위부터 순서대로) L_{easy} , L_{fair} , L_{chal} , GADF[Angle], MTF[Angle] 이미지.

적으로 배열한다. 이는 사람의 이미지 인식 관점을 고려하지 않았다.

L_{chal} : 한 이미지에 가능한 많은 정보를 동시에 포함 하하고자 설계하였다.

GADF : 단일 시계열 데이터를 가시화하는 방법으로, 정규화된 신호 값(\tilde{Y})을 각 시간 인덱스의 반지름으로 사용하여 시계열 데이터를 극좌표(r, ϕ_i)로 표현한다[3]. 이후 시계열 데이터의 인덱스 크기에 따른 $[\sin(\phi_i - \phi_j)]$ 매트릭스를 얻는다.

MTF : 단일 시계열 데이터를 가시화하는 방법으로, 매트릭스의 각 인덱스를 i, j 라고 했을 때, M_{ij} 는 q_i 에서 q_j 로 바뀌는 마르코프 전이 확률로 표현된다[3]. 여기서 q 는 상태를 의미하며 q_i 는 시간 i 때의 상태 q 를 의미한다.

2.3 CNN을 통한 운동 분류

L_{easy} , L_{fair} , L_{chal} 방법을 통해 얻은 이미지는 $227 * 227 * 3$ 크기의 컬러 이미지를 얻게 된다. 그리고 GADF와 MTF 방법을 통해 이미지를 획득하면, 9종류의 이미지를 얻게 되며, 각 이미지를 연속으로 이어붙여 CNN의 입력으로 사용한다. 이때 크기는 $227 * 227 * 27$ 을 갖는다. 위에 명시된 방법을 통해 가시화된 이미지의 분류 정확도를 판단하기 위한 모델로는 AlexNet을 사용한다.

3. 결과 및 토의

표 1은 위에서 설명한 5가지 이미지 가시화 기법에 따른 AlexNet 모델의 분류 정확성과 엔트로피, 희소성을 정리한 표이다. MEAN는 평균, STD는 표준편차를 의미한다. 정확성은 10번 시뮬레이션 하여 얻어낸 결과의 평균과 표준편차를 얻어냈으며, 엔트로피와 희소성은 가시화한 이미지를 바탕으로 구하여 평균과 표준편차를 계산한다.

결과를 살펴보면 이미지의 분류 확률은 모두 90% 이상으로 잘 분류한다. 엔트로피는 MTF가 2.551로 가장 낮은 값을 갖는다. 희소성은 L_{chal} 가 0.296으로 가장 높으며 GADF가 0.032로 가장 낮다. 추가적으로 실제로 시뮬레이션 진행했을 때, L_{easy} , L_{fair} , L_{chal} , GADF는 10번 중 9번 이상 완벽히 분류하는 모습을 보여준다. 그러나 MTF 같은 경우는 완벽히 분류를 성공적으로 수행하는 경우가 10번 중 7번으로 다른 이미지 가시화 기법에 비해 성능의 차이가 있음을 확인했다. 이는 정보의 양을 의미하는 엔트로피 값을 통해 그 이유를 추적할 수 있다. MTF의 엔트로피를 다른 이미지화 기법들과 비교해보면 다소 적은 값을 갖는 것을 볼 수 있다. 따라서 컴퓨터에게 주어지는 정보가 타 방법들보다 적기 때문에

표 1. 5가지 종류의 이미지를 AlexNet 모델의 입력으로 넣어 얻은 결과

정확도	L_{easy}	L_{fair}	L_{chal}	GADF	MTF
MEAN	1.000	1.000	0.992	0.975	0.946
STD	0.000	0.000	0.026	0.079	0.108
엔트로피	L_{easy}	L_{fair}	L_{chal}	GADF	MTF
MEAN	4.565	4.558	5.345	7.047	2.551
STD	0.183	0.181	0.225	0.042	0.042
희소성	L_{easy}	L_{fair}	L_{chal}	GADF	MTF
MEAN	0.272	0.273	0.296	0.032	0.267
STD	0.049	0.048	0.053	0.004	0.004

이러한 결과를 보이는 것으로 해석 할 수 있다.

인간의 이미지 인식관점을 고려하여 설계된 L_{easy} 와 L_{fair} 를 살펴보자. L_{easy} 가 L_{fair} 보다 더 우수한 결과를 거둘 것으로 기대하였으나, 통계적으로 유의미한 결과를 얻지 못했다. 또한, 가시화 기법은 다르나 거의 동일한 엔트로피 값을 통해, 컴퓨터는 이미지를 인식하는 방법에 있어, 사람과는 본질적으로 차이가 있음을 알 수 있다.

희소성은 이미지에서 0의 비율을 의미한다. 희소성이 높다는 것은 이미지에서 0의 비율이 높다는 것으로, 이미지를 표현하는데 필요한 데이터의 비율이 줄어들음을 의미한다. 즉, 정확도가 잘 나오는 이미지화 기법 중, 엔트로피와 희소성이 둘 다 높을수록 컴퓨터에게 더 최적화된 이미지임을 알 수 있다. GADF는, 엔트로피가 7.047이지만 희소성은 0.032로 낮은 값을 갖는 것을 볼 수 있다. 대조적으로 L_{chal} 는 엔트로피가 5.345이고 희소성이 0.296으로 가장 높음을 볼 수 있다. 따라서, 엔트로피와 희소성이 둘 다 높을 때, 최적의 분류성능을 보인 것은 L_{chal} 로, 이 기법이 5가지 방법 중 머신러닝을 사용한 시계열 데이터 분류 문제에 있어, 최적화된 기법이라 할 수 있다.

4. 결론

본 논문에서는 시계열 데이터를 다양한 방법을 사용하여 이미지로 가시화한 후, 가시화된 이미지를 CNN의 입력으로 넣어 분류 정확도를 구하였다. 이후 가시화 방법에 따른 이미지의 엔트로피, 희소성을 고려한 민감도 분석을 진행하였다. 향후 과제로는 CNN의 입력 텐서에 어텐션 기법을 적용하여 이미지를 분석하고자 한다. 만약 덤벨컬에 대해 어텐션을 적용하여 어텐션 영역을 알고 있다고 생각해보면, 새로운 샘플이 들어왔을 때 해당 영역만 분석 해도 덤벨컬 운동 중인지의 여부를 판단할 수 있을 것이라 생각된다.

참 고 문 헌

- [1] J. Yoo, et al., "Classifying Upper Arm Gym-Workouts via Convolutional Neural Network by Imputing a Biopotential-Kinematic Relationship", Applied Sciences, Vol. 11, No. 6, p. 2845, 2021.
- [2] Y. Li, et al., "Exploiting Kernel Sparsity and Entropy for Interpretable CNN Compression", Proceedings of IEEE conference on Computer Vision and Pattern Recognition, pp.2800-2809, 2019.
- [3] Y. Li, et al., "Group Sparsity: The Hinge Between Filter Pruning and Decomposition for Network Compression," in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 8018-8027, June, 2020.
- [4] Z. Wang, et al., "Imaging Time-Series to Improve Classification and Imputation," in Proceedings of the 24th International Conference on Artificial Intelligence, pp. 3939-3945, 2015.